

TRƯỜNG ĐẠI HỌC ...
KHOA ...

BÁO CÁO CUỐI KỲ

Môn: Xử lý ngôn ngữ tự nhiên

Đề tài 05

Dóng hàng câu Hán – Việt cho *Đại Việt Sử Ký Toàn Thư*

bằng mô hình CroCoAlign (EACL 2024): tái lập, đánh giá trên gold gán tay
và cải tiến bằng giải mã đơn điệu

Học viên: Ngô Trường Minh Đạt
Giảng viên hướng dẫn: ...

Tháng 9 năm 2026

Đóng hàng câu Hán – Việt cho *Đại Việt Sử Ký Toàn Thư* bằng CroCoAlign:

tái lập, đánh giá trên gold gán tay và cải tiến

Ngô Trường Minh Đạt

Môn Xử lý ngôn ngữ tự nhiên – Đề tài 05 – Mã nguồn, dữ liệu và kết quả: kho CK_XLNNTN, nhánh
eval-manual-gold

Tóm tắt

Đóng hàng câu (*sentence alignment*) là bước tạo ngữ liệu song song cho dịch máy và nghiên cứu văn bản cổ. Báo cáo này thực hiện đề tài 05: xây dựng ngữ liệu Hán cổ – Việt hiện đại từ bản fulltext *Đại Việt Sử Ký Toàn Thư* (14 mục Ngoại kỷ, 1 703 câu Hán / 1 833 câu Việt), cài đặt và chạy lại CroCoAlign [1] – hệ đóng hàng neural có ngữ cảnh, đạt SOTA trên Opus Books – từ mã nguồn gốc với checkpoint chính thức trên stack phần mềm hiện đại, rồi đánh giá và cải tiến. Khác với cách đánh giá bằng *silver gold* sinh từ chính mô hình (vòng tròn), chúng tôi gán tay 185 nhóm liên kết trên 3 mục làm tập kiểm tra độc lập, tách DEV/TEST, chọn cấu hình bằng cross-validation, và so với hai baseline phi-neural. Kết quả: CroCoAlign zero-shot đạt F_1 strict 0,529 (tinh chỉnh: 0,565); giữ nguyên bộ mã hoá LaBSE của checkpoint nhưng thay bộ giải mã bằng quy hoạch động đơn điệu đạt **0,918** (+39 điểm); một baseline thuần từ vựng Hán-Việt không cần mô hình neural đạt **0,934**. Phân tích cho thấy với song ngữ dịch sát, ràng buộc thứ tự quan trọng hơn chất lượng embedding, và silver gold không thể dùng để chấm mô hình cùng gốc. Toàn bộ pipeline tái lập bằng một lệnh trên CPU.

1 Giới thiệu

Cho hai tài liệu là bản dịch của nhau, *đóng hàng câu* tìm các nhóm câu tương ứng (1-1, 1- n , n -1, n - m , hoặc câu không có cặp). Đây là bước nền cho dịch máy, tra cứu song ngữ và số hoá văn bản cổ. Cặp Hán cổ – Việt của *Đại Việt Sử Ký Toàn Thư* (ĐVSKTT) có ba đặc thù: (i) văn bản Hán cổ **không có dấu câu**, nên ngay việc xác định “câu” đã là bài toán; (ii) khoảng cách ngôn ngữ và thời đại lớn – mô hình đa ngữ hiện đại được huấn luyện trên tiếng Trung hiện đại, không phải văn ngôn thế kỷ XV; (iii) bản dịch chèn nhiều chú giải, niên đại và tách/gộp câu, nên đóng hàng không thuần 1-1.

Đề tài yêu cầu: (1) tiền xử lý dữ liệu cho phù hợp mô hình; (2) cài đặt và chạy lại CroCoAlign [1] theo bài báo EACL 2024; (3) thực nghiệm, đánh giá, và có thể cải tiến. Đóng góp của báo cáo:

- Pipeline cào và tiền xử lý 14 mục ĐVSKTT, giải quyết tách câu Hán cổ bằng dấu câu của *phiên âm Hán-Việt* đi kèm ở nguồn (Mục 4).
- Tái lập CroCoAlign với checkpoint chính thức trên torch 2.x / transformers 5.x mà không sửa mã gốc (Mục 5).
- Bộ gold **gán tay** 185 nhóm, giao thức DEV/TEST + cross-validation, scorer độc lập khớp `evaluate.py` gốc, hai baseline phi-neural (Mục 6).
- Hai cải tiến giữ nguyên bộ mã hoá của CroCoAlign nhưng thay bộ giải mã bằng quy hoạch động đơn điệu, tăng F_1 strict từ 0,529 lên 0,918; và bằng chứng định lượng rằng silver gold sinh từ mô hình thiên vị cấu trúc (Mục 7–8).

2 Nghiên cứu liên quan

Phương pháp thống kê. Gale và Church [4] đóng hàng bằng tỉ lệ độ dài câu và quy hoạch động (DP) đơn điệu với các bước 1-1, 1-0, 0-1, 1-2, 2-1, 2-2; đơn giản nhưng vẫn là baseline mạnh khi hai bản đi song song. Hunalign và Bleualign [5] thêm từ điển hoặc bản dịch máy làm tín hiệu.

Phương pháp nhúng câu. Vecalign [2] dùng embedding đa ngữ (LASER) với DP xấp xỉ đa mức, tuyến tính theo độ dài, và định nghĩa thước đo strict/lax $P/R/F_1$ mà CroCoAlign và báo cáo này dùng lại. LaBSE [3] là bộ nhúng câu 109 ngôn ngữ huấn luyện bằng translation-ranking, cho cosine giữa bản dịch cao và ổn định, được dùng làm bộ mã hoá trong CroCoAlign. **CroCoAlign** [1] là hệ đầu tiên end-to-end, có ngữ cảnh: quyết định từng cặp câu bằng một bộ phân loại neural trên embedding đã được ngữ-cảnh-hoá, không cần DP; đạt macro- F_1 strict 87,5 trên 20 cặp ngôn ngữ Opus Books so với 85,9 của Vecalign. Điểm khác biệt của báo cáo này là dữ liệu *ngoài phân phối* (Hán cổ, gần đơn điệu tuyệt đối) và việc kiểm chứng CroCoAlign bằng gold gán tay thay vì gold tự sinh.

3 Mô hình CroCoAlign

3.1 Kiến trúc

Hình 1 tóm tắt kiến trúc (theo [1], kiểm chứng lại trong mã nguồn `pl_modules/pl_module.py`). Cho câu nguồn $s_1..s_n$ và câu đích $t_1..t_m$:

1. **Bộ nhúng câu LaBSE (đóng băng)** cho $E_{s_i}, E_{t_j} \in \mathbb{R}^{768}$.
2. **Bộ mã hoá ngữ cảnh:** một Transformer kiểu DistilBERT khởi tạo ngẫu nhiên (6 lớp, 6 đầu, dropout 0,2), nhận *chuỗi embedding câu* của một tài liệu làm đầu vào (`inputs_embeds`) và nhờ positional embedding + attention tạo ra embedding có ngữ cảnh C_{s_i}, C_{t_j} . Đây là đóng góp chính của bài báo: câu được đặt trong ngữ cảnh các câu lân cận trước khi so khớp.
3. **Đầu phân loại:** với mọi cặp (i, j) tính tích Hadamard $C_{s_i} \odot C_{t_j}$, đưa qua $\text{Linear}(768 \rightarrow 384) \rightarrow \text{Dropout} \rightarrow \text{ReLU} \rightarrow \text{Linear}(384 \rightarrow 1)$ và sigmoid, cho xác suất M_{ij} ; ngưỡng 0,5 quyết định liên kết. Mỗi câu nguồn có thể nối với 0, 1 hoặc nhiều câu đích và ngược lại.

3.2 Huấn luyện


Hàm mất mát là binary cross-entropy trên toàn ma trận, với $\hat{M}$ là ma trận gold:

$$\mathcal{L} = -\frac{1}{nm} \sum_{i,j} \left[\hat{M}_{ij} \log \sigma(M_{ij}) + (1 - \hat{M}_{ij}) \log (1 - \sigma(M_{ij})) \right].$$

Dữ liệu: Opus Books (16 ngôn ngữ, 64 cặp, 251 sách; 231 sách huấn luyện, 10 kiểm định, 10 kiểm tra); 77% liên kết là 1-1. Cấu hình (`conf/nn/default.yaml`): AdamW, lr $5 \cdot 10^{-6}$ (bài báo: 10^{-5}), weight decay 0,01, warmup 10%, batch 64 câu, gradient clipping 10, early stopping (patience 10) theo F_1 strict trên tập kiểm định; huấn luyện trên RTX 3090 Ti. Checkpoint công bố (2,31 GB) chứa cả LaBSE lẫn bộ mã hoá ngữ cảnh và đầu phân loại; báo cáo này **không huấn luyện lại** mà dùng checkpoint đó (zero-shot với Hán cổ – Việt).

3.3 Suy luận trên tài liệu dài

Vì không đưa cả tài liệu vào GPU, CroCoAlign suy luận theo lô (`batch_size=32` câu): **Pointing** – với mỗi lô nguồn, dùng FAISS tìm k câu đích có cosine LaBSE cao nhất với câu đầu lô, **loại ứng viên có vị trí tương đối lệch quá** `min_dist=0,05`, thử từng cửa sổ đích quanh ứng viên và giữ cửa sổ cho nhiều liên kết nhất; **Recovery** – nếu một câu nguồn bị nối với các câu đích không kề nhau,



Hình 1: Kiến trúc CroCoAlign (hình của tác giả [1], kho GitHub Babelscape/CroCoAlign): bộ nhúng câu đóng băng, bộ mã hoá ngữ cảnh và đầu phân loại được huấn luyện; ma trận $n \times m$ với ô xanh là cặp đóng hàng.

chọn lại bằng cosine LaBSE của câu (`labse`) hoặc của câu kèm $N=3$ câu lân cận (`labse-batch`, biến thể tốt nhất trong bài báo). Điểm quan trọng cho phân tích sau này: **mỗi cặp được quyết định độc lập**, không có ràng buộc thứ tự toàn cục như DP.

4 Dữ liệu và tiền xử lý (Yêu cầu 1)

4.1 Nguồn và cấu trúc

Bản fulltext ĐVSKTT của nomfoundation.org gồm 73 mục, mỗi mục nhiều trang khắc in, phân trang phía server bằng POST `curPg`. Mỗi trang có một bảng HTML: ô thứ nhất chứa *chữ Hán* và *phiên âm Hán-Việt xen kẽ theo block*

<chữ Hán> [trang*dòng*cột] <phiên âm Hán-Việt, có dấu câu>

ô thứ hai (“Dịch Quốc Ngữ”) là bản dịch tiếng Việt hiện đại, cùng thứ tự. Ví dụ một block:

按黃帝時建萬國以交趾界於西南遠在百粵之表 [1a*4*1] *Án: Hoàng đế thời, kiến vạn quốc, dĩ Giao Chỉ giới ư Tây Nam, viễn tại Bách Việt chi biểu.*
→ “Xét: Thời Hoàng Đế dựng muôn nước, lấy địa giới Giao Chỉ về phía Tây Nam, xa ngoài đất Bách Việt.”

4.2 Hai phát hiện then chốt

(1) **Dấu câu của phiên âm cho phép tách câu Hán cổ.** Người biên soạn đã đặt dấu chấm/chấm hỏi ở phiên âm; mỗi block Hán tương ứng đúng một đoạn phiên âm kết thúc bằng dấu kết câu, nên block $\approx$ câu. Không cần mô hình tách câu Hán cổ. (2) **Phiên âm là tín hiệu từ vựng nổi hai bản.** Bản dịch hiện đại giữ nguyên rất nhiều từ Hán-Việt (*Sĩ Nhiếp, Giao Châu, Thái thú, Kiến An, Long Biên*); độ trùng âm tiết giữa phiên âm và câu Việt đo được mà không cần mô hình. Phát hiện này dùng cho cả gán nhãn tay (Mục 6.1) lẫn baseline (Mục 6.4).



Hình 2: Pipeline tiền xử lý. Đầu ra zh.jsonl/vi.jsonl đúng định dạng CroCoAlign (mỗi dòng `{"ids": [...], "text": [...]}`); blocks.tsv giữ phiên âm cho gán nhãn và baseline.

4.3 Pipeline

scrape_dvsktt.py chạy được với requests hoặc thuần urllib (POST multipart tự dựng), có retry và delay 0,8 s/trang. preprocess.py: tách block bằng biểu thức chính quy trên marker `[\d+[ab]*\d+*\d+]`, giữ ký tự CJK (kể cả vùng CJK mở rộng B/F), tách câu Việt theo `. ! ? ;` sau khi bỏ nội dung trong ngoặc vuông (chú giải, niên đại). Bảng 1 thống kê 14 mục đã xử lý.

Bảng 1: 14 mục Ngoại kỷ sau tiền xử lý. DEV = mục 1–3, TEST = mục 7, 9, 10.

Mục	Vai trò	Trang	Hán	Việt	Mục	Vai trò	Trang	Hán	Việt
1 Hồng Bàng thị	DEV	9	80	90	8 thuộc Ngô–Tề	–	27	309	312
2 Nhà Thục	DEV	13	112	125	9 Tiền Lý	TEST	6	64	65
3 Nhà Triệu	DEV	35	331	354	10 Triệu Việt Vương	TEST	6	51	59
4 thuộc Tây Hán	–	2	22	24	11 Hậu Lý	–	6	44	46
5 Trưng Nữ Vương	–	2	19	22	12 thuộc Tuỳ–Đường	–	33	350	357
6 thuộc Đông Hán	–	9	83	94	13 Nam Bắc phân tranh	–	5	56	55
7 Sĩ Vương	TEST	11	75	91	14 Nhà Ngô	–	14	107	139

Tổng: 190 trang, **1 703** câu Hán, **1 833** câu Việt

Nhiều thực tế cần lưu ý: bản dịch có $\approx 8\%$ câu nhiều hơn bản Hán (chú giải, tách câu); vài câu cụt do lỗi ở nguồn (“*KỶ TRIỆU V*”, “*là Ki*”); câu bị cắt ngang trang ở cả hai bản (“*Thời Thứ sử Chu*” | “*Phù bị giặc Di giết...*”); chú giải dài (truyện thuyết Chữ Đồng Tử: 1 block Hán ứng với 6 câu Việt).

5 Cài đặt và chạy lại CroCoAlign (Yêu cầu 2)

Mã nguồn được đưa vào kho dưới dạng git submodule ghim commit 2e93992 (HEAD upstream, 09/2024). Repo ghim torch==1.11, pytorch-lightning==1.5, transformers==4.20, faiss-gpu==1.7.2 – không cài được trên phần cứng hiện có (GPU Blackwell sm_120; macOS arm64). Bảng 2 liệt kê các vướng mắc; nguyên tắc là **không sửa mã gốc**, mọi vá lỗi nằm trong wrapper ở scripts/ (run_align.py, run_eval.py, run_eval_tuned.py).

Kiểm chứng. (i) Ví dụ EN↔IT kèm repo cho kết quả đúng, kể cả câu tiêu đề không có cặp; (ii) chạy end-to-end Hán↔Việt với checkpoint chính thức trên hai môi trường: WSL2 + RTX 5050 (env crocoalign: Python 3.10, torch 2.11+cu128, PL 2.6.5) và macOS arm64 CPU (.venv: Python 3.10, torch 2.14, transformers 5.16, sentence-transformers 6.0, PL 2.6.5, faiss-cpu, nn-template-core 0.1.1). Số liệu trong báo cáo lấy từ lần chạy macOS; toàn bộ phần cần torch (CroCoAlign gốc + tuned trên TEST, cải tiến trên 14 mục $\times$ 64 cấu hình) chạy hết trong ≈ 15 phút CPU, mỗi lượt CroCoAlign trên 190 câu TEST ≈ 5 phút kể cả nạp mô hình.

Bảng 2: Vướng mắc khi cài đặt và cách khắc phục

Vấn đề	Nguyên nhân	Khắc phục
torch ghim không chạy	RTX 5050 (sm_120) không tương thích <code>torch==1.11</code> ; macOS không có CUDA	<code>torch 2.11+cu128 (WSL2)</code> / <code>torch 2.14 CPU (macOS)</code>
faiss-gpu không cài được	chỉ có cho CUDA cũ	<code>faiss-cpu</code> ; dữ liệu vài nghìn câu, đủ nhanh
Nạp checkpoint lỗi	PL 2.6 bỏ <code>_load_model_state</code> mà <code>nn_core.load_model</code> gọi; torch 2.6 mặc định <code>weights_only=True</code> ; <code>sentence-transformers ≥3</code> đổi tên module <code>auto_model</code> → <code>model</code>	loader tự viết: giải nén <code>.ckpt.zip</code> , <code>torch.load(weights_only=False)</code> , ánh xạ lại khoá <code>state_dict</code> ; kết quả <code>missing=0</code> , chỉ 2 <code>buffer position_ids</code> thừa (vô hại)
Thiếu phụ thuộc <code>nn-core</code>	phải cài <code>--no-deps</code> để không bị ép <code>lightning</code> cũ	thêm <code>GitPython</code> , <code>python-dotenv</code>
Đường dẫn tương đối	<code>evaluate.py</code> <code>results_*.tsv</code> vào CWD	ghi <code>runner cd</code> vào thư mục đích, dùng đường dẫn tuyệt đối

6 Phương pháp đánh giá và cải tiến (Yêu cầu 3)

6.1 Gold gán tay

Phiên bản đầu của đề tài chấm CroCoAlign bằng *silver gold* sinh từ cosine LaBSE + DP đơn điệu và chọn siêu tham số trên chính tập báo cáo – vừa **vòng tròn** (CroCoAlign cũng dựa trên LaBSE) vừa **tune trên test**. Thiết kế cuối (Bảng 3) sửa cả hai. Ba mục TEST (7, 9, 10; 190 câu Hán, 215 câu Việt) được gán tay bằng cách đọc phiên âm Hán-Việt đối chiếu bản dịch, theo 5 quy tắc: liên kết theo *nội dung* không theo vị trí; nhóm nhỏ nhất có thể; câu cắt ngang cùng chỗ ở hai bản thì ghép từng mảnh, cắt lệch thì gộp $n-m$; chú giải/niên đại/tiêu đề thuộc block chứa nó, bản dịch không có thì để trống; mỗi id xuất hiện đúng một lần (`annot2gold.py` kiểm tra). Kết quả 185 nhóm: 1-1 = 160, 1-2 = 10, 1-3 = 5, 1-6/1-7 = 2, 2-1 = 3, 2-2 = 2, 1-0 = 3. Mọi quyết định không phải 1-1 có chú thích trong `data/annotation/*.align.txt`; tiêu chí và quy trình rà soát độc lập ghi trong `data/annotation/README.md`. Gold này **độc lập hoàn toàn với LaBSE/CroCoAlign**.

Bảng 3: Thiết kế DEV / TEST

	DEV	TEST
Mục Gold	1 Hồng Bàng, 2 Nhà Thục, 3 Nhà Triệu <i>silver</i> : DP đơn điệu trên cosine LaBSE (<code>build_silver.py</code>)	7 Sĩ Vương, 9 Tiền Lý, 10 Triệu Việt Vương gán tay 185 nhóm
Quy mô	523 / 569 câu	190 / 215 câu
Dùng để	chọn <code>min_dist</code> , ngưỡng của CroCoAlign tuned	báo cáo ; cấu hình các hệ DP chọn bằng CV <code>leave-one-section-out</code>

6.2 Thước đo

Theo Vecalign [2] và `evaluate.py` của CroCoAlign: một liên kết dự đoán là *đúng strict* nếu trùng hoàn toàn với một nhóm gold (cả tập câu nguồn lẫn tập câu đích), *đúng lax* nếu có ít nhất một câu nguồn và một câu đích chung với nhóm gold chứa câu nguồn đó. P tính trên các liên kết dự đoán (kể cả liên kết rỗng), R tính trên các nhóm gold không rỗng, F_1 là trung bình điều hoà; điểm cuối

là trung bình 3 mục. `scripts/score.py` tái hiện đúng logic này bằng Python thuần và được kiểm chứng khớp ba chữ số thập phân với `evaluate.py` trên 6 tổ hợp (3 mục $\times$ 2 cấu hình), nên mọi hệ đều chấm trên cùng một thước đo và chấm được không cần GPU.

6.3 Chọn cấu hình: vì sao cross-validation thay cho DEV

Với CroCoAlign, hai siêu tham số suy luận (`min_dist`, ngưỡng) được chọn trên DEV. Với các hệ dùng DP, DEV silver **suy biến**: silver được sinh bởi đúng thuật toán “cosine LaBSE + DP”, nên hệ LaBSE+DP đạt $F_1 = 1,000$ trên DEV với mọi cấu hình gần gốc – DEV không phân biệt được gì và luôn chọn trọng số $w = 1$. Vì vậy cấu hình các hệ DP được chọn bằng **cross-validation leave-one-section-out trên gold gán tay**: với mỗi mục TEST, chọn cấu hình có F_1 strict trung bình cao nhất trên *hai mục còn lại*, rồi chấm mục bị giữ lại; không mục nào tự chọn cấu hình cho mình (`pick_config.py --cv`). Dòng “chọn trên DEV silver” vẫn được giữ trong bảng kết quả làm đối chứng.

6.4 Baseline phi-neural

Cả hai baseline dùng cùng một bộ giải mã DP đơn điệu (Mục 6.5) và chỉ khác ma trận tương đồng S : **Gale–Church độ dài**: $S_{ij} = \exp(-z_{ij}^2/2)$ với $z_{ij} = (\log(\ell_j^v/\ell_i^h) - \log \bar{r})/\sigma$, ℓ^h là số chữ Hán, ℓ^v số âm tiết Việt, $\bar{r}$ tỉ lệ toàn mục, $\sigma = 0,6$. **Hán-Việt lexical**: Dice có trọng số IDF giữa tập âm tiết của phiên âm A_i và của câu Việt B_j (chữ thường, bỏ dấu câu và số):

$$S_{ij} = \frac{2 \sum_{w \in A_i \cap B_j} \text{idf}(w)}{\sum_{w \in A_i} \text{idf}(w) + \sum_{w \in B_j} \text{idf}(w)}, \quad \text{idf}(w) = \log \frac{N+1}{\text{df}(w) + 0,5}$$

tính trên toàn bộ câu của mục. IDF làm giảm trọng số các hư từ (*chi, nhi, đã, và, của*) và tên riêng.

6.5 Bộ giải mã đơn điệu và hai cải tiến

Gọi $D(i, j)$ là điểm đúng hàng tốt nhất của i câu Hán đầu với j câu Việt đầu:

$$D(i, j) = \max \left\{ \begin{aligned} &D(i-1, j-1) + S_{ij} - \tau; \quad D(i-1, j) - \gamma; \quad D(i, j-1) - \gamma; \\ &D(i-1, j-2) + S_{i, \{j-1, j\}} - \tau - \mu; \quad D(i-2, j-1) + S_{\{i-1, i\}, j} - \tau - \mu \end{aligned} \right\}$$

với τ ngưỡng (điểm âm nếu tương đồng thấp hơn τ thì thà để trống), γ phạt câu không có cặp, $\mu = \gamma$ phạt gộp. Điểm gộp $S_{i, \{j-1, j\}}$ có hai cách: *trung bình hai ô* ($c=0$) hoặc *văn bản ghép* ($c=1$): tương đồng giữa câu Hán và *hai câu Việt ghép lại* – với lexical là Dice trên hợp hai tập âm tiết, với LaBSE là cosine với embedding của chuỗi ghép (mã hoá thêm $m-1$ cặp câu Việt kề nhau và $n-1$ cặp câu Hán kề nhau). Truy vết cho các nhóm 1-1, 1-0, 0-1, 1-2, 2-1. Độ phức tạp $O(nm)$; mục dài nhất (350×357) chạy dưới một giây.

Cải tiến 1 – LaBSE(ckpt)+DP: lấy `model.transformer` (chính bộ LaBSE trong checkpoint CroCoAlign) mã hoá mọi câu, $S = \cos$, giải mã bằng DP trên. Mọi thứ của CroCoAlign được giữ nguyên trừ bộ giải mã ở Mục 3.3. **Cải tiến 2 – LaBSE+Hán-Việt+DP**: $S = w \cdot \cos_{\text{LaBSE}} + (1 - w) \cdot S^{\text{lex}}$, cùng DP. Lưới cấu hình: baseline $\tau \in \{0,10; 0,15; 0,20\}$, $\gamma \in \{0,05; 0,10\}$, $c \in \{0, 1\}$ (12 cấu hình); LaBSE $w \in \{1; 0,7; 0,5; 0,3\}$, $\tau \in \{0,15; 0,25; 0,35; 0,45\}$, cùng γ, c (64 cấu hình; $w = 1$ là cải tiến 1). Embedding được cache (`data/emb/*.npz`, 4 MB) nên lưới tái sinh được không cần checkpoint.

Bảng 4: Kết quả trên TEST (gold gán tay, 185 nhóm), trung bình 3 mục. s = strict, l = lax. Cấu hình các hệ DP chọn bằng CV (Mục 6.3); CV chọn $c=1$ ở mọi fold của mọi hệ.

Hệ thống	P_s	R_s	$F_{1,s}$	P_l	R_l	$F_{1,l}$
CroCoAlign (gốc: min_dist 0,05, ngưỡng 0,5)	0,536	0,522	0,529	0,648	0,642	0,645
CroCoAlign (tuned: 0,15 / 0,20, chọn trên DEV)	0,569	0,561	0,565	0,669	0,669	0,669
Gale–Church độ dài + DP	0,869	0,890	0,879	0,947	0,965	0,956
Hán-Việt lexical + DP	0,930	0,939	0,934	0,993	1,000	0,997
Cải tiến 1: LaBSE(ckpt) + DP	0,914	0,922	0,918	0,995	0,995	0,995
Cải tiến 2: LaBSE + Hán-Việt ($w=0,3$) + DP	0,923	0,932	0,927	0,993	0,993	0,993
<i>Đối chứng:</i> cải tiến 1, cấu hình chọn trên DEV silver	0,834	0,854	0,844	0,957	0,972	0,965

Bảng 5: F_1 strict / lax theo từng mục TEST, và trên DEV silver (chỉ để tham khảo)

Hệ thống	7 Sĩ Vương	9 Tiền Lý	10 Triệu Việt Vương	DEV silver
CroCoAlign (gốc)	0,489 / 0,629	0,587 / 0,619	0,510 / 0,688	0,609 / 0,669
CroCoAlign (tuned)	0,565 / 0,648	0,619 / 0,651	0,510 / 0,708	0,646 / 0,717
Gale–Church độ dài + DP	0,801 / 0,938	1,000 / 1,000	0,837 / 0,929	0,849 / 0,941
Hán-Việt lexical + DP	0,910 / 1,000	0,984 / 1,000	0,908 / 0,990	0,882 / 0,961
Cải tiến 1: LaBSE + DP	0,882 / 0,986	0,984 / 1,000	0,888 / 1,000	1,000 / 1,000
Cải tiến 2: LaBSE + HV + DP	0,910 / 1,000	0,984 / 1,000	0,888 / 0,980	–

7 Kết quả

Ba nhận xét trực tiếp từ bảng: (i) CroCoAlign zero-shot chỉ đạt 0,53–0,57 strict trên gold gán tay, thấp hơn nhiều so với 87,5 mà tác giả báo cáo trên Opus Books – dữ liệu ở đây ngoài phân phối; (ii) tinh chỉnh chọn trên DEV cho +3,6 điểm trên TEST, đúng như +3,7 trên DEV, tức không overfit; (iii) mọi hệ dùng DP đơn điệu vượt CroCoAlign 31–40 điểm, và cùng bộ mã hoá LaBSE của checkpoint đi từ 0,529 lên 0,918 chỉ nhờ đổi bộ giải mã.

8 Phân tích

8.1 Nguồn lỗi của CroCoAlign là bộ giải mã, không phải encoder

Bảng 6 liệt kê lỗi điển hình của CroCoAlign gốc ở mục 7 (33/75 câu Hán sai). Ba kiểu lỗi: **bỏ sót** câu dài có nội dung rõ ràng (zh_3, zh_7, zh_8) – xác suất phân loại dưới 0,5 dù cosine LaBSE của cặp đúng cao; **nhầm sang câu xa** cùng chủ đề (zh_9 → vi_56, cách 46 câu) – cho thấy quyết định từng cặp độc lập, không có ràng buộc “câu sau phải nằm sau câu trước”; **bắt một phần** nhóm 1- n (zh_6 chỉ nói vi_6). Cả ba đều biến mất khi giữ nguyên embedding và giải mã bằng DP: ràng buộc đơn điệu loại bỏ ứng viên xa, và điểm cộng dồn theo đường đi bù cho những cặp có tương đồng vừa phải. Bản dịch ĐVSKTT theo sát thứ tự bản Hán (không có $n-m$ chéo nào trong 185 nhóm gold), nên giả thiết đơn điệu đúng gần tuyệt đối – khác với tài liệu văn học nhiều mà CroCoAlign được thiết kế cho.

8.2 Khi giải mã đúng, tín hiệu tương đồng ít quan trọng

Cùng bộ giải mã: độ dài thuần 0,879; Hán-Việt 0,934; LaBSE 0,918; hợp nhất 0,927. Ba hệ đầu bảng chênh nhau ≤ 3 nhóm trên 185 – trong sai số của tập test nhỏ. Encoder neural đa ngữ **không** hơn tín hiệu từ vừng miễn phí sẵn có ở nguồn; hợp nhất ($w = 0,3$, tức lexical chiếm 70%) nhỉnh

Bảng 6: Ví dụ lỗi của CroCoAlign gốc trên mục 7 Sĩ Vương (gold gán tay)

Câu Hán	Gold	CroCoAlign dự đoán
zh_5 土王紀	vi_4 “KỶ SĨ VƯƠNG.”	vi_5 “SĨ VƯƠNG.” (tiêu đề ngắn, nhầm câu kè)
zh_9 父賜漢桓帝時爲日南太守	vi_10 “Cha là Tứ, thời Hán Hoàn Đế làm Thái thú Nhật Nam.”	vi_56 “(Tân nhận chức năm Kiến An thứ 6 thời Hán).” – cách 46 câu
zh_7 姓士諱變字彥威蒼梧廣信人也	vi_8 “Họ Sĩ, tên huý là Nhiếp, tự là Ngạn Uy...”	∅ (bỏ sót)
zh_6 土王在位四十年壽九十年王寬厚...	vi_5 + vi_6 + vi_7 (1-3)	vi_6 (chỉ “Ở ngôi 40 năm, thọ 90 tuổi.”)

hơn LaBSE thuần nhưng chưa vượt lexical thuần. Với văn ngôn thế kỷ XV, cosine LaBSE của cặp đúng chỉ khoảng 0,5–0,7 (ví dụ 按黃帝時建萬國 ↔ “Xét: Thời Hoàng Đế dựng muôn nước”: 0,52), thấp hơn nhiều so với cặp ngôn ngữ hiện đại.

8.3 Gộp trên văn bản ghép là chi tiết quan trọng nhất của DP

CV chọn $c=1$ ở mọi fold của mọi hệ. Với gộp trung bình, nhóm 1-2 có một câu Việt ngắn (“Hữu ty hỏi vì có gì?”) bị tách thành 1-1 + câu bỏ trống vì ô của câu ngắn kéo trung bình xuống dưới τ ; ghép văn bản rồi mới so thì tương đồng của cả nhóm được giữ. Riêng Hán-Việt lexical đi từ 0,859 ($c=0$) lên 0,934 ($c=1$), số nhóm sai từ 24 xuống 11.

8.4 Silver gold thiên vị cấu trúc – hai bằng chứng định lượng

(i) LaBSE+DP đạt đúng 1,000 trên DEV silver (silver là điểm bất động của nó); chọn cấu hình trên DEV cho 0,844 trên TEST, chọn bằng CV cho 0,918 – chênh 7,4 điểm chỉ do cách chọn. (ii) Trên DEV silver, gộp-trung-bình *thắng* gộp-văn-bản-ghép (0,933 so với 0,882); trên gold gán tay thì *ngược lại* (0,859 so với 0,934), vì silver được sinh bởi chính DP gộp-trung-bình. Kết luận phương pháp: số liệu chỉ trên silver – như ở phiên bản đầu của đề tài – không được coi là chân trị, và gold gán tay là bắt buộc khi hệ được chấm và hệ sinh gold cùng gốc.

8.5 Lỗi còn lại và hạn chế

Hệ tốt nhất sai 11/185 nhóm, *toàn bộ* là 1- n với $n \geq 3$ (chú giải dài, lời bình sử thần tách nhiều câu Việt; block về bóng nêu ứng với 7 câu Việt) hoặc 2-2 (niên đại + lời tâu cất lệch) – ngoài tập bước của DP, không phải do tín hiệu. Hạn chế của nghiên cứu: gold 185 nhóm / 3 mục còn nhỏ (3 nhóm $\approx 1,6$ điểm F_1) và do một người gán, chưa đo đồng thuận; CV ba fold trên ba mục còn thô; CroCoAlign tuned vẫn chọn trên DEV silver; chưa thử fine-tune bộ mã hoá ngữ cảnh của CroCoAlign trên cặp Hán cổ – Việt.

9 Kết luận

Đề tài đã hoàn thành ba yêu cầu: (1) pipeline cào và tiền xử lý 14 mục ĐVSKTT, giải quyết tách câu Hán cổ bằng dấu câu của phiên âm; (2) cài đặt và chạy lại CroCoAlign từ mã nguồn gốc với checkpoint chính thức trên stack hiện đại, không sửa mã gốc, chạy được trên cả GPU lẫn CPU; (3) đánh giá bằng gold gán tay độc lập với mô hình, chọn cấu hình bằng CV, có baseline đối chứng, và cải tiến. Kết quả chính: CroCoAlign zero-shot đạt F_1 strict 0,529 (tuned 0,565); giữ nguyên encoder của nó nhưng giải mã đơn điệu đạt 0,918; baseline thuần từ vựng Hán-Việt đạt 0,934. Bài

học: với song ngữ dịch sát, **ràng buộc thứ tự quan trọng hơn chất lượng embedding**, và **silver gold sinh từ mô hình không dùng được để chấm mô hình cùng gốc**. Hướng tiếp theo: mở rộng gold và đo đồng thuận, thêm bước DP 1-3/2-2, fine-tune CroCoAlign trên cặp Hán cổ – Việt sinh từ chính pipeline này.

Tài liệu

- [1] F. M. Molfese, A. Bejgu, S. Tedeschi, S. Conia, R. Navigli. CroCoAlign: A Cross-Lingual, Context-Aware and Fully-Neural Sentence Alignment System for Long Texts. *Proc. EACL 2024 (Long)*, 2209–2220. <https://aclanthology.org/2024.eacl-long.135/>. Mã nguồn: <https://github.com/Babelscape/CroCoAlign>.
- [2] B. Thompson, P. Koehn. Vecalign: Improved Sentence Alignment in Linear Time and Space. *Proc. EMNLP-IJCNLP 2019*, 1342–1348.
- [3] F. Feng, Y. Yang, D. Cer, N. Arivazhagan, W. Wang. Language-agnostic BERT Sentence Embedding. *Proc. ACL 2022*, 878–891.
- [4] W. A. Gale, K. W. Church. A Program for Aligning Sentences in Bilingual Corpora. *Computational Linguistics* 19(1):75–102, 1993.
- [5] R. Sennrich, M. Volk. Iterative, MT-based Sentence Alignment of Parallel Texts. *Proc. NODALIDA 2011*.
- [6] Ngô Sĩ Liên và các sử thần triều Lê. *Đại Việt Sử Ký Toàn Thư*. Bản fulltext Hán – phiên âm – dịch, Vietnamese Nôm Preservation Foundation. <https://www.nomfoundation.org/nom-project/history-of-greater-vietnam/Fulltext?uiLang=vn>

A Hướng dẫn tái lập

Gói nộp (kho CK_XLNNTN, nhánh eval-manual-gold): *dataset* – data/raw (thô theo trang), data/processed (đầu vào CroCoAlign), data/gold_manual + data/annotation (gold gán tay và phiếu); *source* – scripts/ (toàn bộ do nhóm viết), CroCoAlign/ (sub-module mã gốc); *model* – không huấn luyện mô hình mới; dùng checkpoint chính thức của tác giả (Google Drive id 1DwOAB501oUc01Be6gImX8TI7RqxD8XCw, 2,31 GB) và LaBSE trên HuggingFace (sentence-transformers/LaBSE); các hệ cải tiến là phi tham số (cấu hình trong data/results/*.json), embedding cache data/emb/; *kết quả* – data/pred/, data/results/, RESULTS.md.

Môi trường (macOS arm64 hoặc Linux; GPU không bắt buộc):

```
git clone --recurse-submodules <repo> && cd CK_XLNNTN && git checkout eval-manual-gold
uv venv --python 3.10 .venv
uv pip install -p .venv/bin/python torch transformers sentence-transformers faiss-cpu
jsonlines \
scikit-learn hydra-core==1.3.2 omegaconf==2.3.0 torchmetrics pytorch-lightning
GitPython python-dotenv
uv pip install -p .venv/bin/python --no-deps nn-template-core==0.1.1
uvx gdown 1DwOAB501oUc01Be6gImX8TI7RqxD8XCw -O CroCoAlign/checkpoints/crocoalign.ckpt
```

Phiên bản đã kiểm chứng: Python 3.10, torch 2.14.0, transformers 5.16.1, sentence-transformers 6.0.1, pytorch-lightning 2.6.5, faiss-cpu 1.x, nn-template-core 0.1.1. Suy luận là tất định (không seed).

Bước 1 – dữ liệu (thuần Python, không cần thư viện ngoài; cào ≈5 phút):

```
python3 scripts/scrape_dvsktt.py --list # liệt kê 73 mục
python3 scripts/scrape_dvsktt.py --out data/raw --delay 0.8 --sections 1-Ky-Hong-Bang-
thi ... 14-Ky-nha-Ngo
python3 scripts/preprocess.py --raw data/raw --out data/processed
```

Bước 2 – gold (đã có sẵn; chạy lại khi sửa file gán nhãn):

```
python3 scripts/make_annot_sheet.py --section 7-Ky-Si-Vuong --out data/annotation/7-Ky-
Si-Vuong.sheet.md
python3 scripts/annot2gold.py --section 7-Ky-Si-Vuong \
--align data/annotation/7-Ky-Si-Vuong.align.txt --out data/gold_manual/7-Ky-Si-Vuong
.jsonl
bash scripts/build_silver_all.sh # silver DEV (can LaBSE)
```

Bước 3 – chạy toàn bộ hệ thống và chấm điểm (một lệnh, ≈ 15 phút CPU; trên WSL/GPU đặt PY tới env crocoalign):

```
PY=.venv/bin/python bash scripts/run_wsl_all.sh
```

Lệnh này lần lượt: CroCoAlign gốc và tuned trên TEST (run_eval.py, run_eval_tuned.py $\rightarrow$ data/pred/crocoalign*_test/results_*.tsv); run_improved.py sinh 64 cấu hình LaBSE(+Hán-Việt)+DP cho 14 mục; grid_baseline.py sinh 12 cấu hình cho mỗi baseline; pick_config.py --cv chọn cấu hình và ghi data/results/<hệ>_test.json; make_results_table.py chèn bảng vào RESULTS.md. Chấm một hệ bất kỳ: python3 scripts/score.py --gold-dir data/gold_manual --pred-dir <thư mục dự đoán>.

Bước 4 – báo cáo: cd report && tectonic bao_cao.tex (XeLaTeX; font Times New Roman và Songti SC của macOS – trên hệ khác thay bằng TeX Gyre Termes và Noto Serif CJK SC).