

TRƯỜNG ĐẠI HỌC ...
KHOA ...

BÁO CÁO CUỐI KỲ

Môn: Xử lý ngôn ngữ tự nhiên

Đề tài 05

Dóng hàng câu Hán – Việt cho

Đại Việt Sử Ký Toàn Thư

bằng mô hình CroCoAlign (EACL 2024) và các phương pháp đối chứng, cải
tiến

Học viên: Ngô Trường Minh Đạt
Giảng viên hướng dẫn: ...

Tháng 9 năm 2026

Mục lục

1	Mục tiêu và yêu cầu đề tài	2
2	Tổng quan mô hình CroCoAlign	2
3	Cài đặt và chạy lại CroCoAlign (Yêu cầu 2)	2
4	Dữ liệu và tiền xử lý (Yêu cầu 1)	3
4.1	Khảo sát nguồn	3
4.2	Hai phát hiện then chốt	3
4.3	Thực hiện	3
5	Thiết kế đánh giá (Yêu cầu 3)	4
6	Kết quả	5
7	Phân tích và cải tiến	6
7.1	Nguồn lỗi của CroCoAlign là bộ giải mã, không phải encoder	6
7.2	Tinh chỉnh CroCoAlign	6
7.3	Khi giải mã đúng, tín hiệu tương đồng ít quan trọng	6
7.4	Gộp trên văn bản ghép là chi tiết quan trọng nhất của DP	6
7.5	Silver gold thiên vị cấu trúc – hai bằng chứng	6
7.6	Lỗi còn lại	6
8	Hạn chế và hướng phát triển	7
9	Kết luận	7
A	Cấu trúc kho mã và cách tái lập	7

1 Mục tiêu và yêu cầu đề tài

Đề tài yêu cầu ba việc trên cặp ngôn ngữ Hán cổ – Việt hiện đại, dữ liệu *Đại Việt Sử Ký Toàn Thư* (bản fulltext của nomfoundation.org):

1. **Tiền xử lý dữ liệu** để đầu vào phù hợp với mô hình.
2. **Cài đặt và chạy lại mô hình CroCoAlign** từ mã nguồn GitHub theo bài báo EACL 2024 [1].
3. **Thực nghiệm và đánh giá** kết quả dóng hàng câu; có thể **cải tiến** để đạt kết quả tốt hơn.

Tài nguyên: bài báo [1]; mã nguồn <https://github.com/Babelscape/CroCoAlign>; dữ liệu <https://www.nomfoundation.org/nom-project/history-of-greater-vietnam/Fulltext?uiLang=vn>. Toàn bộ mã, dữ liệu và kết quả của báo cáo này nằm trong kho CK_XLNNTN (nhánh eval-manual-gold).

2 Tổng quan mô hình CroCoAlign

CroCoAlign [1] là hệ dóng hàng câu neural, end-to-end, có ngữ cảnh. Kiến trúc gồm (i) bộ nhúng câu **LaBSE** [3] cho 109 ngôn ngữ, có cả tiếng Trung và tiếng Việt; (ii) một **bộ mã hoá ngữ cảnh** (DistilBERT nhỏ) đặt mỗi câu trong ngữ cảnh tài liệu; (iii) một **đầu phân loại MLP** trên tích ngoài câu nguồn $\times$ câu đích, dự đoán cặp có dóng hàng hay không.

Suy luận: tính embedding $\rightarrow$ FAISS truy hồi $k=200$ câu đích gần nhất $\rightarrow$ lọc theo khoảng cách vị trí tương đối (`min_dist`) $\rightarrow$ mô hình chấm điểm từng cặp $\rightarrow$ thủ tục *recovery* bằng LaBSE cho cặp nhiều–nhiều $\rightarrow$ gom cụm. Hệ hỗ trợ liên kết 1-1, 1- n , n -1, n - m và câu không có cặp. Định dạng vào: hai file `.jsonl`, mỗi dòng một câu `{"ids": [...], "text": [...]}`; ra: TSV.

3 Cài đặt và chạy lại CroCoAlign (Yêu cầu 2)

Mã nguồn được đưa vào kho dưới dạng *git submodule* ghim commit 2e93992 (HEAD của upstream) nên tái lập được chính xác. Repo ghim `torch==1.11, pytorch-lightning==1.5, transformers==4.20` – không cài được trên phần cứng và hệ điều hành hiện tại. Bảng 1 tóm tắt các vướng mắc và cách khắc phục; nguyên tắc là **không sửa mã gốc**, mọi vá lỗi nằm trong các wrapper ở `scripts/`.

Kiểm chứng: chạy ví dụ EN $\leftrightarrow$ IT kèm repo cho kết quả đúng; sau đó chạy end-to-end Hán $\leftrightarrow$ Việt với checkpoint LaBSE chính thức (2,31 GB) trên cả WSL2 + GPU và macOS arm64 (CPU). Số liệu trong báo cáo này lấy từ lần chạy trên macOS (`.venv`: torch 2.14, transformers 5.16, sentence-transformers 6.0, PL 2.6.5).

Bảng 1: Vướng mắc khi cài đặt và cách khắc phục

Vấn đề	Nguyên nhân	Khắc phục
GPU không chạy được torch repo ghim	RTX 5050 là kiến trúc Blackwell (sm_120), không tương thích torch==1.11	torch 2.11+cu128 (WSL); torch 2.14 CPU (macOS)
faiss-gpu không cài được	chỉ có bản cho CUDA cũ	faiss-cpu (vài nghìn câu, đủ nhanh)
Nạp checkpoint lỗi	PL 2.6 bỏ <code>_load_model_state</code> ; torch 2.6 mặc định <code>weights_only=True</code> ; sentence-transformers đổi tên <code>auto_model</code> → <code>model</code>	loader vá lỗi <code>run_align.py</code> : giải nén <code>.ckpt.zip</code> , nạp <code>weights_only=False</code> , ánh xạ lại khoá ⇒ <code>missing=0</code>
Thiếu phụ thuộc của nn-core	cài <code>--no-deps</code> để tránh ép lighting cũ	thêm <code>GitPython</code> , <code>python-dotenv</code>

4 Dữ liệu và tiền xử lý (Yêu cầu 1)

4.1 Khảo sát nguồn

Mỗi mục (kỷ) của bản fulltext phân trang phía server (POST `curPg`). Mỗi trang có một bảng gồm ô *Hán* + *phiên âm* xen kẽ theo *block* <chữ Hán> [trang*dòng*cột] <phiên âm Hán-Việt có dấu câu> và ô *Dịch Quốc Ngữ* là bản dịch tiếng Việt hiện đại, cùng thứ tự.

4.2 Hai phát hiện then chốt

1. **Dấu câu của phiên âm** cho phép tách câu chữ Hán cổ (vốn không có dấu câu): mỗi block $\approx$ một câu. Đây là lời giải cho bài toán khó nhất của tiền xử lý.
2. Phiên âm Hán-Việt đi kèm 1:1 với từng câu Hán là một **tín hiệu từ vựng miễn phí** nói sang bản dịch: tên người, địa danh, chức quan, niên hiệu đều là từ Hán-Việt (*Sĩ Nhiếp*, *Giao Châu*, *Thái thú*, *Kiến An*). Tín hiệu này dùng được cho cả gán nhãn tay lẫn đóng hàng.

4.3 Thực hiện

`scrape_dvsktt.py` (chạy được với `requests` hoặc thuần `urllib`) cào 14 mục Ngoại kỷ; `preprocess.py` tách câu Hán theo marker, làm sạch bản dịch (bỏ chú giải trong ngoặc vuông, niên đại), tách câu Việt theo dấu kết câu, xuất `zh.jsonl/vi.jsonl` đúng định dạng CroCoAlign và `blocks.tsv` (Hán ↔ phiên âm). Thống kê ở Bảng 2.

Nhiều thực tế: bản dịch chèn chú giải, tách/gộp câu; vài câu cụt do lỗi ở nguồn (“*KỶ TRIỆU V*”, “*là Ki*”); câu bị cắt ngang trang ở cả hai bản.

Bảng 2: Dữ liệu sau tiền xử lý

	Mục	Trang	Câu Hán	Câu Việt
Tổng	14	190	1 703	1 833
DEV (mục 1, 2, 3)	3	57	523	569
TEST (mục 7, 9, 10)	3	23	190	215

5 Thiết kế đánh giá (Yêu cầu 3)

Phiên bản đầu của đề tài chấm CroCoAlign bằng một *silver gold* sinh từ cosine LaBSE + quy hoạch động đơn điệu, và chọn siêu tham số trên chính tập báo cáo. Cách làm đó có hai lỗi: **đánh giá vòng tròn** (CroCoAlign cũng dựa trên LaBSE) và **tune trên test**. Thiết kế cuối sửa cả hai (Bảng 3).

Bảng 3: Thiết kế DEV / TEST

	DEV	TEST
Mục	1 Hồng Bàng, 2 Nhà Thục, 3 Nhà Triệu	7 Sĩ Vương, 9 Tiền Lý, 10 Triệu Việt Vương
Gold	<i>silver</i> : DP đơn điệu trên cosine LaBSE	gán tay : đọc phiên âm Hán-Việt đối chiếu bản dịch
Quy mô	523 / 569 câu	190 / 215 câu, 185 nhóm
Dùng để	chọn cấu hình CroCoAlign tuned	báo cáo ; cấu hình các hệ DP chọn bằng CV leave-one-section-out

Gold gán tay. Ba mục TEST được gán thủ công bằng cách đọc phiên âm Hán-Việt đối chiếu bản dịch, theo năm quy tắc (liên kết theo nội dung không theo vị trí; nhóm nhỏ nhất có thể; câu cắt ngang cùng chỗ thì ghép từng mảnh; chú giải/niên đại thuộc block chứa nó; mỗi id xuất hiện đúng một lần). Mọi quyết định không phải 1-1 có chú thích trong `data/annotation/*.align.txt`; `annot2gold.py` kiểm tra phủ. Phân bố nhóm: 1-1 = 160, 1-2 = 10, 1-3 = 5, 1-6/1-7 = 2, 2-1 = 3, 2-2 = 2, 1-0 = 3. Gold này **độc lập hoàn toàn với LaBSE/CroCoAlign**.

Không chọn cấu hình trên tập báo cáo. CroCoAlign tuned chọn trên DEV. Với các hệ dựa trên DP, DEV *silver suy biến*: hệ LaBSE+DP đạt $F_1 = 1,000$ trên DEV vì silver được sinh bởi chính thuật toán đó, nên DEV không phân biệt được cấu hình. Vì vậy cấu hình các hệ DP chọn bằng **cross-validation leave-one-section-out trên gold gán tay**: với mỗi mục TEST, chọn cấu hình tốt nhất trên hai mục còn lại rồi chấm mục bị giữ lại. Không mục nào tự chọn cấu hình cho mình.

Thước đo. $P/R/F_1$ **strict** (nhóm khớp hoàn toàn) và **lax** (khớp một phần) theo Vecalign [2], đúng như `evaluate.py` của CroCoAlign. Scorer độc lập `score.py` (thuần Python) tái hiện logic này và được kiểm chứng khớp ba chữ số với số liệu của `evaluate.py` gốc.

Các hệ thống so sánh. Bảng 4.

Bảng 4: Các hệ thống

Hệ thống	Mô tả
CroCoAlign (gốc)	checkpoint LaBSE chính thức, $\min_dist=0,05$, ngưỡng 0,5
CroCoAlign (tuned)	$\min_dist=0,15$, ngưỡng 0,20 – chọn trên DEV
Gale–Church độ dài + DP	prior tỉ lệ độ dài chữ Hán / âm tiết Việt [4]; DP đơn điệu 1-1/1-0/0-1/1-2/2-1
Hán-Việt lexical + DP	IDF-weighted Dice giữa phiên âm Hán-Việt và câu Việt; cùng DP
Cải tiến 1: LaBSE(ckpt) + DP	bộ mã hoá LaBSE của chính checkpoint CroCoAlign $\rightarrow$ cosine $\rightarrow$ DP đơn điệu
Cải tiến 2: LaBSE + Hán-Việt + DP	$S = w \cdot \cos_{LaBSE} + (1 - w) \cdot \text{lex}_{HánViệt} \rightarrow$ DP

Mọi hệ DP có tùy chọn *gộp trên văn bản ghép*: điểm cho bước 1-2 / 2-1 tính trên hai câu ghép lại (với LaBSE: mã hoá cặp câu ghép) thay vì trung bình hai ô. Lưới cấu hình: hệ baseline $t \in \{0,10; 0,15; 0,20\}$, $g \in \{0,05; 0,10\}$, $c \in \{0, 1\}$; hệ LaBSE thêm $w \in \{1; 0,7; 0,5; 0,3\}$, $t \in \{0,15; 0,25; 0,35; 0,45\}$.

6 Kết quả

Bảng 5: Kết quả trên TEST (gold gán tay, 185 nhóm), trung bình 3 mục. Cấu hình các hệ DP chọn bằng CV.

Hệ thống	P_s	R_s	$F_{1,s}$	P_l	R_l	$F_{1,l}$
CroCoAlign (gốc)	0,536	0,522	0,529	0,648	0,642	0,645
CroCoAlign (tuned, chọn trên DEV)	0,569	0,561	0,565	0,669	0,669	0,669
Gale–Church độ dài + DP	0,869	0,890	0,879	0,947	0,965	0,956
Hán-Việt lexical + DP	0,930	0,939	0,934	0,993	1,000	0,997
Cải tiến 1: LaBSE(ckpt) + DP	0,914	0,922	0,918	0,995	0,995	0,995
Cải tiến 2: LaBSE + Hán-Việt + DP	0,923	0,932	0,927	0,993	0,993	0,993
(đối chứng) cải tiến 1, chọn cấu hình trên DEV silver	0,834	0,854	0,844	0,957	0,972	0,965

Bảng 6: F_1 strict / lax theo từng mục TEST

Hệ thống	7 Sĩ Vương	9 Tiền Lý	10 Triệu Việt Vương
CroCoAlign (gốc)	0,489 / 0,629	0,587 / 0,619	0,510 / 0,688
CroCoAlign (tuned)	0,565 / 0,648	0,619 / 0,651	0,510 / 0,708
Gale–Church độ dài + DP	0,801 / 0,938	1,000 / 1,000	0,837 / 0,929
Hán-Việt lexical + DP	0,910 / 1,000	0,984 / 1,000	0,908 / 0,990
Cải tiến 1: LaBSE + DP	0,882 / 0,986	0,984 / 1,000	0,888 / 1,000
Cải tiến 2: LaBSE + HV + DP	0,910 / 1,000	0,984 / 1,000	0,888 / 0,980

Trên DEV (silver), CroCoAlign gốc đạt 0,609 / 0,669 và tuned 0,646 / 0,717; mức tăng +3,7 điểm strict trên DEV tái hiện thành +3,6 trên TEST.

7 Phân tích và cải tiến

7.1 Nguồn lỗi của CroCoAlign là bộ giải mã, không phải encoder

Giữ nguyên LaBSE của chính checkpoint CroCoAlign, chỉ thay bộ giải mã “FAISS top- k + lọc vị trí + ngưỡng từng cặp” bằng quy hoạch động đơn điệu, F_1 strict đi từ 0,529 lên **0,918** (+39 điểm). Bản dịch *Đại Việt Sử Ký Toàn Thư* theo sát thứ tự bản Hán; CroCoAlign quyết định từng cặp độc lập nên bỏ phí ràng buộc thứ tự – đó là nguồn lỗi chính. Mô hình được thiết kế cho tài liệu nhiễu, phi đơn điệu, không phải cho song ngữ dịch sát như ở đây.

7.2 Tinh chỉnh CroCoAlign

Bản dịch tiếng Việt có nhiều câu hơn (chèn chú giải, tách câu) nên vị trí tương đối trôi dạt ($\approx 6,5\%$ ở mục dài), vượt bộ lọc gốc `min_dist=0,05` và loại nhầm ứng viên đúng. Nới lên 0,15 và hạ ngưỡng quyết định từ 0,5 xuống 0,20 (tăng recall) cho +3,7 trên DEV và +3,6 trên TEST – nhất quán, không overfit.

7.3 Khi giải mã đúng, tín hiệu tương đồng ít quan trọng

Cùng bộ giải mã: độ dài thuần 0,879; Hán-Việt 0,934; LaBSE 0,918; hợp nhất 0,927. Ba hệ đầu bảng chênh nhau ≤ 3 nhóm trên 185. Encoder neural **không hơn** tín hiệu từ vừng miễn phí có sẵn ở nguồn trên dữ liệu này. Hợp nhất với $w = 0,3$ nhỉnh hơn LaBSE thuần nhưng chưa vượt lexical thuần.

7.4 Gộp trên văn bản ghép là chi tiết quan trọng nhất của DP

CV chọn $c = 1$ ở mọi fold của mọi hệ. Với gộp trung bình, nhóm 1-2 có một câu Việt ngắn (“*Hữu ty hỏi vì có gì?*”) bị tách thành 1-1 + câu bỏ trống; Hán-Việt lexical đi từ 0,859 ($c=0$) lên 0,934 ($c=1$).

7.5 Silver gold thiên vị cấu trúc – hai bằng chứng

(i) LaBSE+DP đạt 1,000 trên DEV silver (silver là điểm bất động của nó); chọn cấu hình trên DEV cho 0,844 trên TEST, chọn bằng CV cho 0,918. (ii) Trên DEV silver, gộp-trung-bình thắng gộp-văn-bản-ghép (0,933 so với 0,882); trên gold gán tay thì ngược lại (0,859 so với 0,934). Số liệu chỉ trên silver – như ở phiên bản đầu của đề tài – không được coi là chân trị.

7.6 Lỗi còn lại

Hệ tốt nhất sai 11/185 nhóm, toàn bộ là **1- n** với $n \geq 3$ (chú giải dài, lời bình sử thần bị tách nhiều câu Việt, vd. block Hán về bóng nêu ứng với 7 câu Việt) hoặc **2-2** (niên đại + lời tâu cắt

lệch ở hai bản) – ngoài tập bước của DP. Lỗi của CroCoAlign: tiêu đề/tên ngắn (涇陽王, 壬戌元年) bị bỏ sót; vị trí trôi khi bản dịch chèn chú giải.

8 Hạn chế và hướng phát triển

- Gold gán tay 185 nhóm / 3 mục – đủ để phân xử nhưng còn nhỏ (3 nhóm $\approx 1,6$ điểm F_1); nên mở rộng và có người gán thứ hai để đo đồng thuận. CV ba fold trên ba mục cũng còn thô.
- CroCoAlign tuned vẫn chọn cấu hình trên DEV silver; có thể chọn lại bằng CV.
- Mở rộng DP với bước 1-3 / 2-2 để xử lý 11 lỗi còn lại; fine-tune LaBSE trên cặp Hán cổ – Việt.

9 Kết luận

Đề tài đã (1) xây dựng pipeline cào và tiền xử lý cho 14 mục *Đại Việt Sử Ký Toàn Thư*, giải quyết tách câu Hán cổ bằng dấu câu của phiên âm; (2) cài đặt và chạy lại CroCoAlign từ mã nguồn gốc với checkpoint chính thức trên stack hiện đại mà không sửa mã gốc; (3) đánh giá bằng gold gán tay độc lập với mô hình, chọn cấu hình bằng CV, có baseline đối chứng. Kết quả chính: CroCoAlign zero-shot đạt F_1 strict 0,529 (tuned 0,565); giữ nguyên encoder của nó nhưng giải mã đơn điệu đạt 0,918; và một baseline thuần từ vựng Hán-Việt, không cần mô hình neural, đạt 0,934. Bài học phương pháp: với song ngữ dịch sát, ràng buộc thứ tự quan trọng hơn chất lượng embedding, và silver gold sinh từ mô hình không thể dùng để chấm mô hình cùng gốc.

A Cấu trúc kho mã và cách tái lập

```
CK_XLNNTN/  
CroCoAlign/          submodule ma goc (.gitmodules) + checkpoints/crocoalign.  
  ckpt  
  scripts/  
    scrape_dvsktt.py  preprocess.py          # YC1  
    run_align.py      run_eval.py  run_eval_tuned.py # YC2: wrapper va loader, chay  
    CroCoAlign goc/tuned  
    score.py          # scorer doc lap (= evaluate.py)  
    baseline_hanviet.py  grid_baseline.py      # baseline phi-neural + luoi cau  
    hinh  
    make_annot_sheet.py  annot2gold.py         # gan nhan tay -> gold  
    run_improved.py      pick_config.py        # cai tien LaBSE+DP; chon cau hinh (  
    CV / DEV)  
    make_results_table.py  run_wsl_all.sh      # bang ket qua; mot lenh cho toan bo  
    phan torch
```



```

data/
  raw/   processed/      14 muc
  gold/   silver (DEV)      gold_manual/   gan tay (TEST)
  annotation/   phieu + .align.txt co chu thich + tieu chi gan nhan
  pred/   results/      du doan; JSON so lieu
BAO_CAO.md RESULTS.md PLAN.md report/bao_cao.tex

```

```

# thuan Python 3.9+, khong can thu vien ngoai
python3 scripts/scrape_dvsktt.py --out data/raw --sections 1-Ky-Hong-Bang-thi ...
    14-Ky-nha-Ngo
python3 scripts/preprocess.py --raw data/raw --out data/processed
python3 scripts/annot2gold.py --section 7-Ky-Si-Vuong \
    --align data/annotation/7-Ky-Si-Vuong.align.txt --out data/gold_manual/7-Ky-Si-
    Vuong.jsonl
# phan can torch (CroCoAlign + LaBSE), macOS .venv hoac WSL env crocoalign
PY=.venv/bin/python bash scripts/run_wsl_all.sh      # ~15 phut CPU, tu chen bang
    vao RESULTS.md

```

Tài liệu

- [1] F. Molfese, A. Bejgu, S. Tedeschi, S. Conia, R. Navigli. *CroCoAlign: A Cross-Lingual, Context-Aware and Fully-Neural Sentence Alignment System for Long Texts*. Proc. EACL 2024 (Long Papers), 2209–2220. <https://aclanthology.org/2024.eacl-long.135/>
- [2] B. Thompson, P. Koehn. *Vecalign: Improved Sentence Alignment in Linear Time and Space*. Proc. EMNLP-IJCNLP 2019.
- [3] F. Feng, Y. Yang, D. Cer, N. Arivazhagan, W. Wang. *Language-agnostic BERT Sentence Embedding*. Proc. ACL 2022.
- [4] W. A. Gale, K. W. Church. *A Program for Aligning Sentences in Bilingual Corpora*. Computational Linguistics 19(1), 1993.
- [5] Ngô Sĩ Liên và các sử thần triều Lê. *Đại Việt Sử Ký Toàn Thư*. Bản fulltext, Vietnamese Nôm Preservation Foundation. <https://www.nomfoundation.org/>